In letteratura molto è stato fatto al fine di estrarre informazioni strutturate da Wikipedia, in particolare per evincere relazioni lessicali e semantiche fra concetti, oltre che informazioni fattuali, al fine di ottenere una ricca rete semantica.

Due sistemi complementari

Il punto forte di Wikipedia consiste nella sua ricchezza semantica (implicita ed esplicita), ossia il fatto che contenga moltissime *named entities* (es. Apple come compagnia). D'altro canto la natura enciclopedica di Wikipedia è anche il suo limite più grande: non tutti i significati sono rappresentati da una pagina ad hoc (es. l'apple frutto/ albero sono mergiati nella stessa pagina), mentre questo tipo di copertura lessicale è fornita da WordNet.

I due strumenti, data la loro natura complementare, possono essere combinati per ottenere il dizionario enciclopedico multilingua **BabelNet**.

Spendiamo ora qualche parola per delineare le caratteristiche principali dei due sistemi.

Ricordiamo che i concetti in Giacché un termine può avere Piccolo WordNet sono suddivisi per PoS, diversi significati, la stessa parola ed ogni concetto è rappresentato recap: può apparire in diversi synset. mediante un synset. $\{play_n^1, drama_n^1, dramatic play_n^1\}$ Per esempio, il concetto di play come opera drammatica sarà A pedice abbiamo espresso la PoS (noun) e ad apice il numero del significato (il numero del senso) (ad espresso dal sequente synset: esempio play nel synset relativo al concetto di "giocata" avrà apice 2). WordNet $\{play_n^8, child's play_n^2\}$ L'apice su play significa che se cerchiamo Es. Il concetto di play come play su wordnet questo significato è "attività che fa un bambino" è espresso nel synset numero 8 espresso la seguente synset: L'apice su child's play significa che se cerchiamo

child's play su wordnet questo significato è

espresso dal synset numero 2

Wikipiedia è una enciclopedia multilingua online. Si tratta di un'opera collaborativa open source creata e corretta da volontari di tutto il mondo al fine di ottenere una sorta di enciclopedia di larghissimo spettro.

Ogni articolo in Wikipedia è rappresentato da una pagina (Wikipage) la quale può presentare informazioni a proposito di un **concetto specifico** (es. Play (theatre)) oppure una **named entity** (es. William Shakespeare).

Wikipedia

Play (theatre)

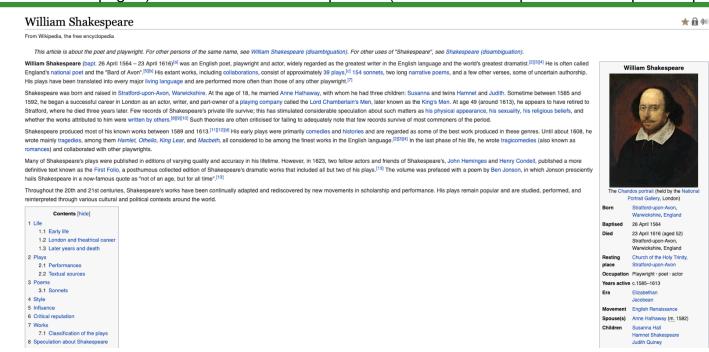
From Wikipedia, the free encyclopedia

Il titolo di una Wikipage può contenere un **label** fra parentesi (theatre nell'esempio sopra) utile a disambiguare il concetto di cui parla la pagina. Purtroppo il label potrebbe non bastare per disambiguare un concetto, dato che un singolo significato può avere la sua descrizione distribuita su più pagine.

Il testo di una Wikipage è parzialmente strutturato.

Wikipage

Alcune pagine presentano un **infobox** (una tipo di tabella che riassume le caratteristiche princiapli dell'entità a cui si riferisce la pagina) contenente informazioni puntuali (tendenzialmente questi box sono presenti per le named entity).



Fra le Wikipage vi sono delle **relazioni** espresse mediante:

Redirect pages

usate per inoltrare l'utente ad una Wikipage che contenga il vero e proprio contenuto dell'informazione richiesta. **Es.** Stageplay e Theatrical play redirezionano entrambe a Play (theatre).

Le redirect pages vengono dunque utilizzate per linkare diverse espressioni ad uno stesso concetto e modellano quindi la sinonimia.

Disambiguation pages

usate per collezionare i link a tutti i possibili concetti correlati ad un certo termine.

Es. il termine Play linka sia a Play (theatre) che a Play(activity).

Wikipage relazioni tra pagine

Internal links

usati all'interno di una Wikipage per linkare ad altre pagine dell'enciclopedia laddove si menzioni un concetto presente nel sistema (che sarà quindi naturalmente rilevante rispetto al concetto della Wikipage che lo linka).

Es. Play (theatre) linkerà a Literature, Dialogue, ecc. mentre Play(activity) linkerà a Socialization, Game, ecc.

Inter-language links

usati per linkare Wikipages che trattano lo stesso concetto ma in altre lingue.

Es. Play (theatre) linka alla pagina italiana Dramma.

Categories

ogni Wikipage può avere un certo numero di categorie assegnate.

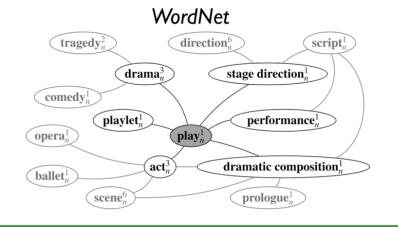
Es. Play (theatre) è categorizzata sotto THEATRE, DRAMA, LITERATURE, ecc.

WordNet e Wikipedia sono dunque rappresentabili come due grafi:

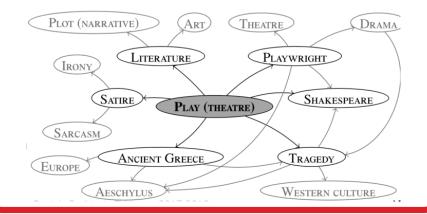
Possiamo facilmente asserire che i due grafi siano complementari nei termini delle informazioni fornite: scopo della prossima sezione è riuscire a combinarli per ottenere un sistema ancora più potente.

Es. notiamo come Wikipedia abbia link molto meno "formali" e più eterogenei rispetto a WordNet.

Due grafi a confronto



In WordNet i nodi sono synset e gli archi sono relazioni lessicali e semantiche tra synset (*iponimia*, *meronimica*, *antonimia*, *etc*)



In Wikipedia i nodi sono Wikipages e gli archi sono hyperlink che le collegano